UNIVERSIDADE KIMPA VITA

INSTITUTO POLITÉCNICO

CURSO DE ENGENHARIA INFORMÁTICA

Trabalho Em Grupo de

Linguagem de Programação II

Tema: Análise Estatística de Dados de Saúde (NumPy e Pandas)

IIIº ANO

TURMA: 101

PERÍODO: MANHÃ

DOCENTES

_____

Moyo Kanivengidio

Índice

Introdução 1
1. Metodologia 2
1.1 Conjunto de Dados 2
1.2 Carregamento e Limpeza de Dados 2
2. Estatísticas Descritivas 3
2.1 Resultados Obtidos 3
2.2 Interpretação 4
3. Análise de Distribuição 4
3.1 Interpretação 4
4. Análise de Correlação 5
4.1 Interpretação 5
Conclusão 6
Referências bibliográficas 7
Relação Nominal dos Integrantes do Grupo 8

Introdução

Com o crescimento do volume de dados na área da saúde, torna-se cada vez mais importante a utilização de ferramentas computacionais para análise e interpretação desses dados. A estatística aplicada, aliada a linguagens de programação como Python, permite extrair informações relevantes que podem auxiliar na compreensão de fenómenos clínicos.

Neste contexto, o presente trabalho tem como objetivo aplicar técnicas de análise estatística a um conjunto de dados simulado de pacientes, utilizando as bibliotecas Pandas.

1. Metodologia

1.1 Conjunto de Dados

Foi utilizado um ficheiro no formato CSV contendo 90 registros de pacientes. As variáveis consideradas para análise estatística foram:

- Idade
- Peso
- Altura
- Colesterol
- Pressão Arterial,

Outras variáveis foram excluídas da análise por não possuírem relevância estatística.

1.2 Carregamento e Limpeza de Dados

O processo de carregamento e limpeza de dados (data preprocessing) constitui uma etapa fundamental em qualquer análise estatística, pois garante que os dados estejam consistentes, completos e adequados para análise.

Inicialmente, o ficheiro CSV foi carregado para um DataFrame utilizando a biblioteca Pandas, permitindo a manipulação estruturada dos dados.

Após o carregamento, foi realizada uma inspeção inicial para identificar possíveis problemas, como:

- Valores ausentes (missing values)
- Tipos de dados incorretos
- Valores inconsistentes ou fora do intervalo esperado (outliers)

Em seguida, foram aplicadas técnicas de limpeza de dados, incluindo:

- **Tratamento de valores ausentes:** os valores nulos foram substituídos pela média das respetivas colunas numéricas, garantindo que não houvesse perda significativa de informação.
- **Remoção de outliers:** foram eliminados valores considerados irreais, como idades superiores a 120 anos.
- **Seleção de variáveis relevantes:** foram mantidas apenas colunas numéricas com significado estatístico (Idade, Peso, Altura e Colesterol), enquanto variáveis como Nome, Telefone e ID foram descartadas da análise.
- **Padronização de tipos de dados:** assegurou-se que todas as variáveis analisadas estivessem em formatos numéricos adequados.

Este processo é essencial, pois dados não tratados podem introduzir erros e enviesar os resultados da análise estatística.

2. Estatísticas Descritivas

As estatísticas calculadas com base no dataset foram as seguintes:

2.1 Resultados Obtidos

Total de Registros: 90 observações em cada variável.

Média:

- Idade: 43.27 anos
- Peso: 72.23 kg
- Altura: 1.71 m
- Colesterol: 206.9 mg/dL

Desvio Padrão:

- Idade: 11.9
- Peso: 12.45
- Altura: 0.09
- Colesterol: 35.97

Valores Mínimos:

- Idade: 22
- Peso: 48.9
- Altura: 1.55
- Colesterol: 150

Valores Máximos:

- Idade: 65
- Peso: 95
- Altura: 1.85
- Colesterol: 278

Quartis:

- 1º Quartil: Idade (33.25), Peso (63.48), Altura (1.63), Colesterol (178.25)
- Mediana: Idade (43), Peso (71.35), Altura (1.70), Colesterol (198.5)
- 3º Quartil: Idade (53.75), Peso (82.95), Altura (1.78), Colesterol (239.5)

Moda:

- Idade: 28
- Peso: 72.8
- Altura: 1.65
- Colesterol: 180

2.2 Interpretação

A média de idade indica uma população adulta com distribuição relativamente equilibrada, uma vez que a mediana é próxima da média.

O peso apresenta um desvio padrão elevado, sugerindo grande variabilidade entre os pacientes. Já a altura apresenta baixa variabilidade, o que é esperado biologicamente.

Os níveis de colesterol apresentam valores médios relativamente elevados (206.9 mg/dL), indicando possível risco cardiovascular em parte da população analisada.

3. Análise de Distribuição

A análise de distribuição tem como objetivo compreender a forma como os dados se distribuem ao longo de determinados intervalos, permitindo identificar padrões, assimetrias e possíveis valores extremos.

Para esta análise, foram construídos histogramas das variáveis Idade, Peso, Altura e Colesterol, utilizando a biblioteca Matplotlib. O histograma representa graficamente a frequência dos valores dentro de intervalos (bins), facilitando a visualização da concentração dos dados.

Além disso, esta abordagem permite avaliar se os dados seguem uma distribuição aproximadamente normal (gaussiana) ou se apresentam desvios significativos.

3.1 Interpretação

A análise dos histogramas revelou que:

- **Idade:** apresenta uma distribuição aproximadamente simétrica, com maior concentração na faixa dos 30 aos 50 anos, indicando predominância de indivíduos adultos.
- **Peso:** demonstra maior dispersão, com valores distribuídos entre aproximadamente 50 kg e 95 kg, sugerindo diversidade significativa nas características físicas dos pacientes.
- **Altura:** apresenta distribuição mais concentrada, com menor variabilidade, o que é consistente com padrões biológicos humanos.
- **Colesterol:** mostra uma distribuição relativamente ampla, com concentração entre 180 e 240 mg/dL, indicando variação nos níveis de risco cardiovascular.

De forma geral, os histogramas permitiram identificar padrões de concentração e dispersão que complementam as estatísticas descritivas, fornecendo uma visão mais intuitiva dos dados.

4. Análise de Correlação

A análise de correlação foi realizada com o objetivo de identificar relações lineares entre as variáveis numéricas do conjunto de dados. Para isso, foi utilizada a matriz de correlação baseada no coeficiente de Pearson, que varia entre -1 e 1.

Valores próximos de 1 indicam forte correlação positiva, valores próximos de -1 indicam forte correlação negativa, e valores próximos de 0 indicam ausência de relação linear significativa.

Esta análise é fundamental para compreender como as variáveis se relacionam entre si, permitindo identificar possíveis associações relevantes no contexto da saúde.

4.1 Interpretação

A partir da matriz de correlação obtida, foram identificadas as seguintes relações:

- **Peso e Altura:** apresentaram correlação positiva, indicando que indivíduos mais altos tendem a ter maior peso. Este resultado é coerente com padrões fisiológicos.
- **Idade e Colesterol:** observou-se uma tendência de correlação positiva, sugerindo que níveis de colesterol tendem a aumentar com a idade.
- **Peso e Colesterol:** pode apresentar correlação moderada, indicando possível relação entre massa corporal e níveis de colesterol.

Algumas variáveis apresentaram correlação fraca, indicando que não possuem relação linear significativa entre si.

É importante destacar que a correlação não implica causalidade. Assim, embora duas variáveis possam estar associadas, isso não significa que uma seja causa direta da outra.

A análise de correlação complementa as estatísticas descritivas, permitindo uma compreensão mais profunda das interações entre as variáveis estudadas.

Conclusão

A análise estatística realizada permitiu compreender o comportamento das variáveis do conjunto de dados de pacientes. A utilização de Python, juntamente com as bibliotecas Pandas, mostrou-se eficaz para manipulação e análise de dados.

Os resultados evidenciam padrões relevantes, como a variabilidade do peso e os níveis elevados de colesterol, que podem indicar riscos à saúde.

Referências bibliográficas

- McKinney, W. (2018). Python for Data Analysis. O'Reilly Media.
- Documentação oficial do Pandas. Disponível em: https://pandas.pydata.org
- Documentação oficial do NumPy. Disponível em: https://numpy.org
- Montgomery, D. C., & Runger, G. C. (2014). Applied Statistics and Probability for Engineers.
- OpenAI. (2026). ChatGPT (modelo GPT-5.3). Disponível em: https://openai.com/chatgpt

Relação Nominal dos Integrantes do Grupo

1. Américo Malungo Sebastião Miguel
2. Bengui Bena Pedro
3. Egas Manuel Ribeiro
4. Matondo Domingos Bunga
5. HermenegiEm [validation.ts](api/src/config/app/validation.ts) tem erros como: Unsafe assignment of an error typed value., linha 5, Unsafe member access .constraints on a type that cannot be resolved. linha 9.ldo Wilson dos Santos Panzo